Präsentation Backend

Stand 30.06.2025

Alessandro Lago, Moritz Wilhelm, Christian Rücker, Maksim Lukianov , Jakob Schauer

Agenda

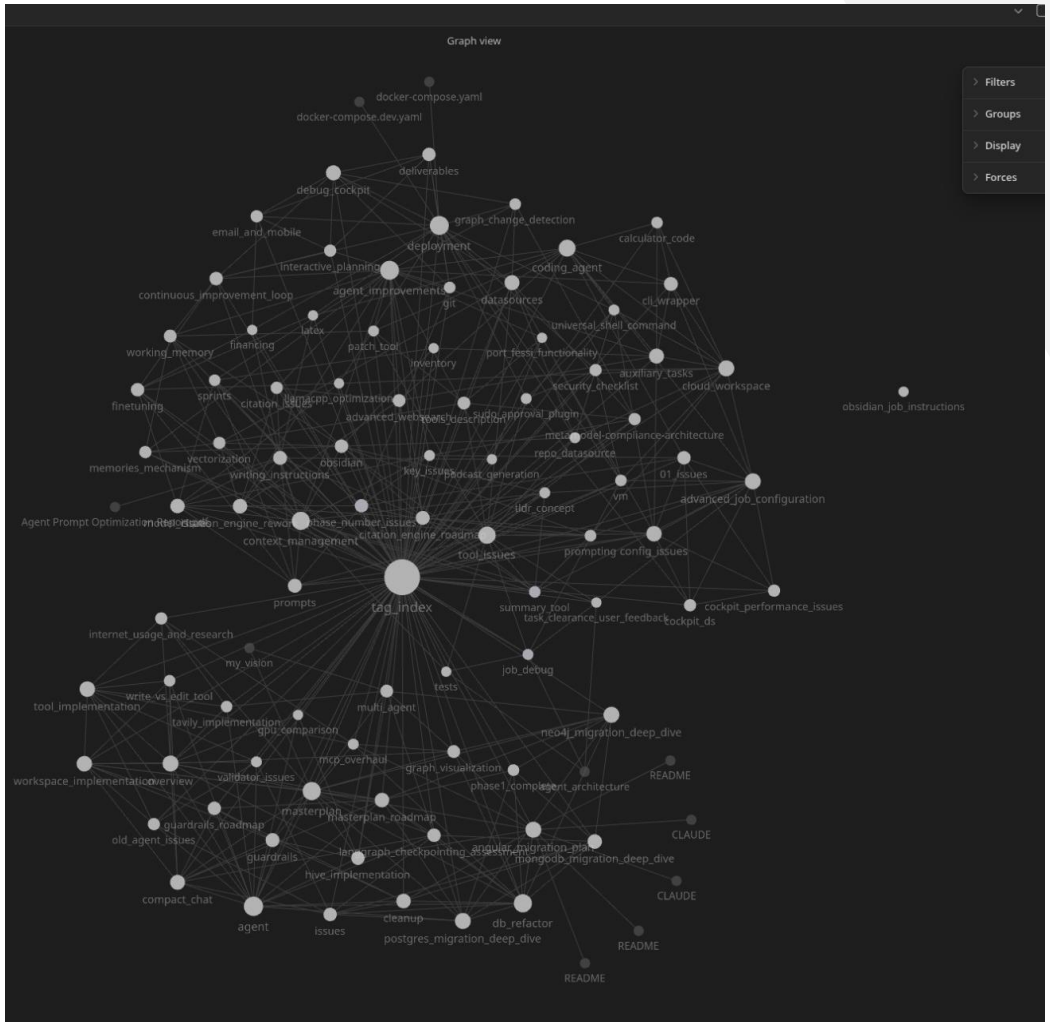
- Erstellen der Grundlage
- ETL-Pipeline
- AVV-Codes
- BMEcat
- Open Food Facts
- Bonus

Erstellen der Grundlage

- Grundlage basierend auf
  - OdeNet
  - WordNet
  - OpenThesaurus
  - Kaikki.org
- Ergebnis
  - ~110k importiert
  - ~85k Nodes nach Cleanup
- Weiteres Raffinement durch LLM-Models notwendig

ETL-Pipeline

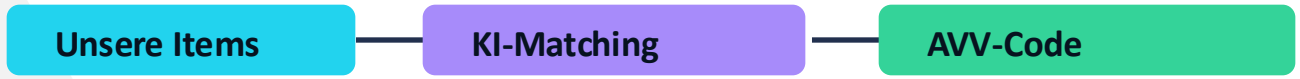
- Pipelines sind soweit fertig
  - Chain für Klassifikation (e.g. AVV codes, Waste Iteam?)
  - Agent für dynamische Anreicherung (e.g. BMEcat, OpenFoodFacts)
- Deployment dieses WE
  - GPUs (e.g. 3 x gpt oss 20b)
  - Neo4j + MongoDB
- Test mit ~200 Seiten Dokumentation



AVV-Codes

34	20110	20110	20110	02 01 10	Code (6-stellig)	3	Metallabfälle	ungefährliche Abfälle	nein
35	20199	20199	20199	02 01 99	Code (6-stellig)	3	Abfälle (anderweitig nicht genannt)	ungefährliche Abfälle	nein
36	20201	20201	20201	02 02 01	Code (6-stellig)	3	Schlämme von Wasch- und Reinigungsvorgängen	ungefährliche Abfälle	nein
37	20202	20202	20202	02 02 02	Code (6-stellig)	3	Abfälle aus tierischem Gewebe	ungefährliche Abfälle	nein
38	20203	20203	20203	02 02 03	Code (6-stellig)	3	für Verzehr oder Verarbeitung ungeeignete Stoffe	ungefährliche Abfälle	nein
39	20204	20204	20204	02 02 04	Code (6-stellig)	3	Schlämme aus der betriebseigenen Abwasserbehandlung TM	ungefährliche Abfälle	nein
40	20299	20299	20299	02 02 99	Code (6-stellig)	3	Abfälle (anderweitig nicht genannt)	ungefährliche Abfälle	nein
41	20301	20301	20301	02 03 01	Code (6-stellig)	3	Schlämme aus Wasch-, Reinigungs-, Schäl-, Zentrifugier- und Abtrennprozessen	ungefährliche Abfälle	nein
42	20302	20302	20302	02 03 02	Code (6-stellig)	3	Abfälle von Konservierungsstoffen	ungefährliche Abfälle	nein
43	20303	20303	20303	02 03 03	Code (6-stellig)	3	Abfälle aus der Extraktion mit Lösemitteln	ungefährliche Abfälle	nein
44	20304	20304	20304	02 03 04	Code (6-stellig)	3	für Verzehr oder Verarbeitung ungeeignete Stoffe	ungefährliche Abfälle	nein
45	20305	20305	20305	02 03 05	Code (6-stellig)	3	Schlämme aus der betriebseigenen Abwasserbehandlung TM	ungefährliche Abfälle	nein

- Waste items Klassifizieren mit Llama 8b oder gpt oss 20b
- Datenbank schleife
  - LLM bekommt Node aus dem Graph + AVV codes liste
  - LLM-Antwortet mit passendem AVV code
  - AVV code wird in Datenbank eingefügt



BME CAT

- Bild von Excel liste oder so
- Daten vorbereitet
- Vorgehen
  - KI-Agent bekommt Reihe
  - KI-Agent sucht passende Node im Graph
  - KI-Agent fügt Informationen ein

BME CAT

Item (Eingabe)	KI findet passenden AVV/EAV-Code	Gefährlich? (*)	Ergebnis für den Bot (kurz)	Was wird im Graph ergänzt?
Energiesparlampe (kaputt)	20 01 21* – quecksilberhaltige Lampen	Ja	**Sonderabfall** → zur Sammelstelle/Hausdienst	Item bekommt `avv_code=20 01 21*`, `hazardous=true`, Kante `HAS_AVV (conf=0.94)`
Computermaus (defekt)	20 01 36 – Elektrogeräte ohne gefährliche Bestandteile	Nein	**E-Schrott** → IT-/E-Schrott-Box	Item bekommt `avv_code=20 01 36`, Kante `HAS_AVV (conf=0.88)`, Kante `DISPOSE_AS → E-Schrott`
AA-Batterie (leer)	20 01 33* – Batterien/Akkus	Ja	**Batteriesammlung** → Batteriebox	Item bekommt `avv_code=20 01 33*`, `hazardous=true`, Kante `HAS_AVV (conf=0.96)`
Pizzakarton (fettig)	20 03 01 – Restmüll (gemischt)	Nein	**Restmüll** (nicht Papier)	Item bekommt `avv_code=20 03 01`, Kante `DISPOSE_AS → Restmüll`, Hinweis „Papier ausgeschlossen“
Glasflasche (leer)	15 01 07 – Glasverpackungen	Nein	**Altglas** → Glascontainer	Item bekommt `avv_code=15 01 07`, Kante `DISPOSE_AS → Altglas`, optional `FOUND_AT → Ort`

Open Food Facts

- 10GB Datenreduktion
- 200 Spalten gekillt

```
== Spalten-Reduktion ==
Input:   big.csv
Output:  big_muellbot.tsv
Delimiter erkannt: '\t'
Spalten gesamt:    215
Spalten behalten:  13
Spalten entfernt:  202
Processed: 1,000,000 rows | Written: 1,000,000 | 36,604 rows/s
Processed: 2,000,000 rows | Written: 2,000,000 | 34,488 rows/s
Processed: 3,000,000 rows | Written: 3,000,000 | 34,387 rows/s
Processed: 4,000,000 rows | Written: 4,000,000 | 34,729 rows/s
FERTIG ✅
Datenzeilen geschrieben: 4,371,128
Dauer: 125.3s
```

Bonus

- Wir haben ca. 5-10 Millionen Requests
  - 7 Tage, 5-10 request/s
  - 3 Modelle, 500 concurrent requests pro Modell
  - Optional SLURM Cluster (A100 ~10% langsamer als L40s)
- Barcode API Anbindung
- Entsorgungsstationen
- Müllcontainer
  - Einschätzung anhand von AVV-Codes
  - Exception handeling