Schema → Datenbedarf

1) Begriffe (Core)

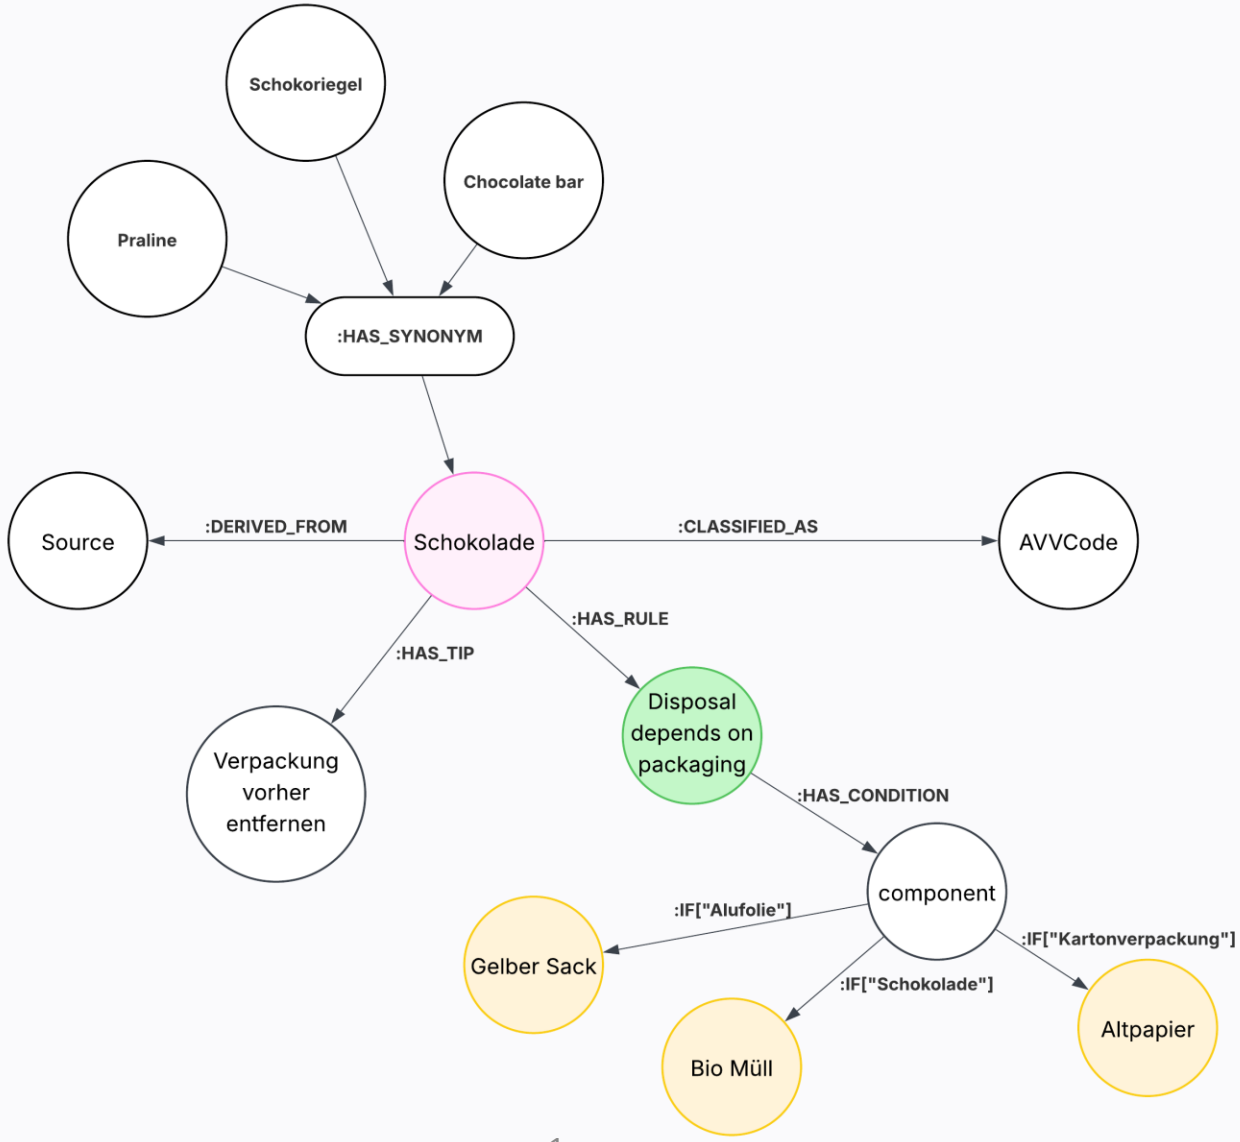
WasteItem, WasteStream, AVVCode, Synonyme
Wir brauchen: Vokabular + Regeln + Standort-Overlay.

2) Regeln (Logic)

DisposalRule, Condition, Instruction/Tip
Regeln müssen „Campus > City“ überschreibenkönnen.

3) Orte (Infra)

Container, Building/Room, Facility + Öffnungszeiten
Große Datenwelten (Produkte/Chemie) nur „ondemand“.



Quellen-Priorisierung (Tiering)

Tier 1 – Must-have

AVV/LoW Codes (Backbone)

Abfall-ABC (Vokabular + Synonyme)

Campus-Orte: Container, Ansprechpartner, Gebäude/Räume

Tier 2 – Good-to-have

OSM/Overpass: externe Facilities (Skeleton)

EAR: Elektro-Gruppen & Routing-Logik

ZSVR / Satzungen: Beleg für Regeln (selektiv)

Tier 3 – Later / On demand

Open Food Facts (Barcode → Packaging)

iFixit (Zerlegehinweise)

PubChem/GESTIS (nur falls Labor-Scope)

Merksatz: Keine 100M+ Vollimporte → wir „destillieren“ auf MVP-Größe.

Key Discoveries

Warum Regeln + Rückfragen nötig sind (statt nur Lookup)

SaaS-Oligopol (DE)
3 Plattformen dominieren kommunale Abfall-Apps
→ Integration als „Connector“ statt 400+ Parser

Mirror-Entry Problem
Gleicher Gegenstand → 2 AVV-Codes
(gefährlich vs. nicht gefährlich)
→ Chatbot muss nachfragen

Regionale Variation
Regeln unterscheiden sich je Stadt/Kreis
z. B. Pizzakarton, Bioplastik
→ Location-aware Overrides

BAM Datenbank kostenlos
Gefahrgut/UN/ADR jetzt frei (seit Juli 2025)
→ kein teures Logistik-Tool nötig

Distillation: Wir importieren nur das Nötige

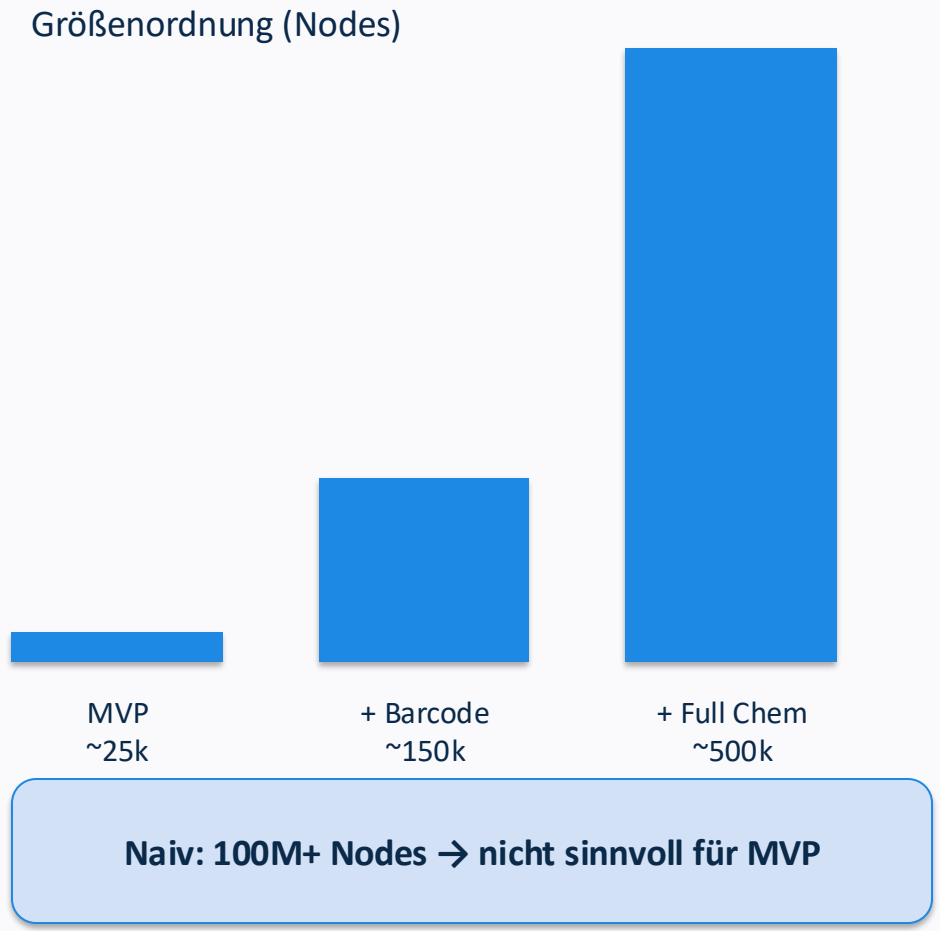
Ziel: Uni-Chatbot („Wie entsorge ich X?“) – nicht Weltwissen

Naiver Import:

- 100+ Mio. Nodes (z. B. PubChem, Icecat, …)
- Für MVP unnötig + unmaintainable

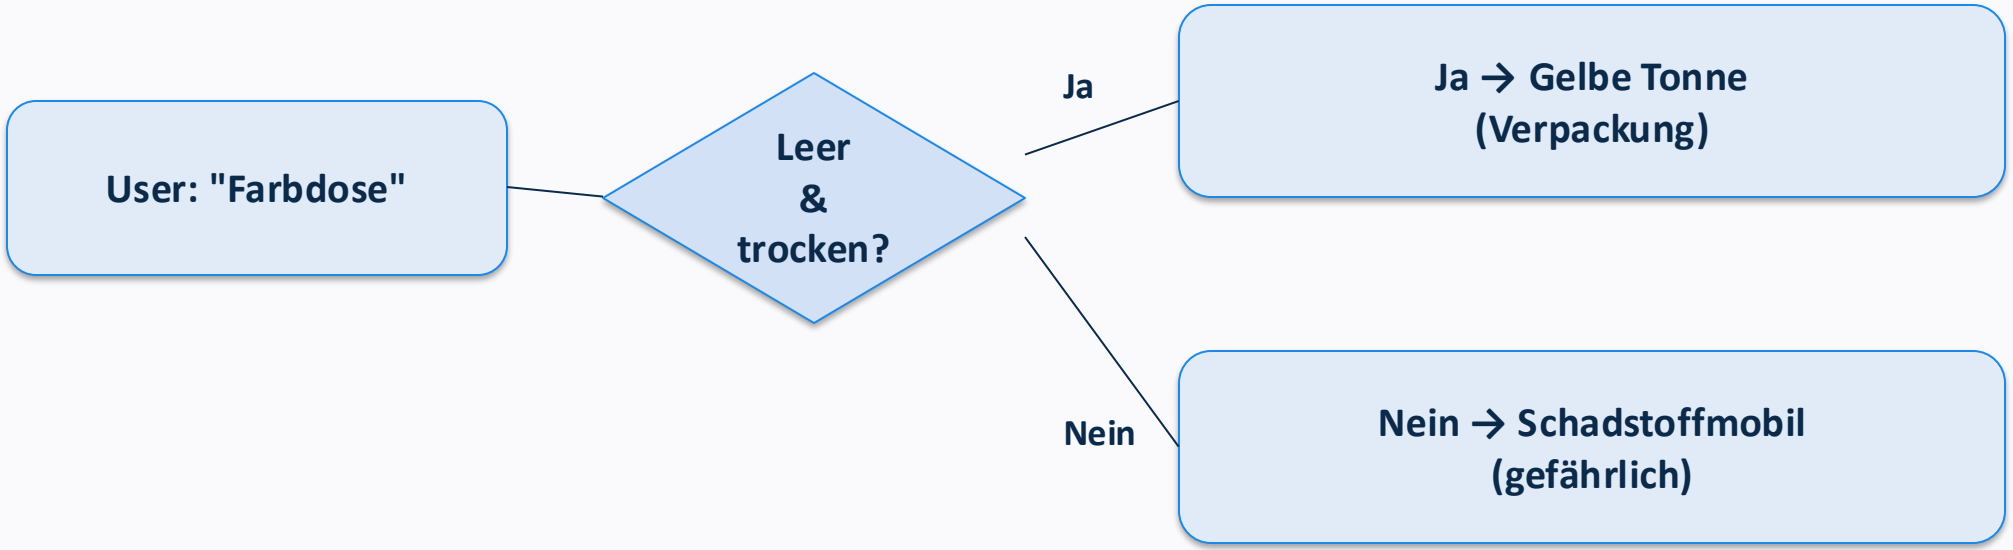
Unser Ansatz (MVP → erweiterbar):

- MVP: ~25k Nodes (Vokabular + Regeln + Facilities)
- + Barcode: ~150k (On-demand per API)
- + Full Chemistry: ~500k (nur falls nötig)



Testcase: Decision Tree (statt „statischer Lookup“)

Gleicher Gegenstand kann je Zustand unterschiedliche Entsorgung haben



Merke: Das ist genau das „Mirror-Entry“-Problem: zwei AVV-Codes → Rückfrage im Chatbot.

Integration: 3 Modi

Je Quelle wählen wir den realistischsten Weg

A) ETL Import

- Für klein & stabil (CSV/JSON).
- Beispiele: AVV, Abfall-ABC, OSM-POIs.
- Pro: schnell & offline nutzbar.
- Contra: Daten müssen „sauber“ sein.

B) API on demand

- Für riesige Datenräume.
- Beispiele: Open Food Facts, iFixit, PubChem.
- Pro: kein Bulk-Import, nur bei Bedarf.
- Contra: Rate-Limits / Caching nötig.

C) Regel-Logik

- Wenn Wissen in Texten steckt.
- Beispiele: Satzungen, ZSVR, LAGA.
- Pro: bildet Wenn-Dann + Rückfragen ab.
- Contra: manuell/LLM-Extraktion, braucht Validierung.

Target für MVP: eher zehntausende Knoten (Items + Orte + wenige Regeln) statt Millionen.

Research Domains

Wir haben relevante Daenquellen für Uni-Entsorgung über 6 Themenfelder gesichte

Domäne	Quellen	Kernaussage (Beispiel)
Food & Grocery	8	Open Food Facts: viele DE-Produkte inkl. Verpackung/Barcode
Consumer Electronics	10	Stiftung EAR: offizielle ElektroG-Gruppen; iFixit: Akku/Repairability
Chemicals & Hazardous	15	PubChem + GESTIS + BAM: Identität, Sicherheit, Gefahrgut
Regulatorik (Deutschland spezifisch)	9	3 Plattformen dominieren Abfall-Apps (Abfall+, MyMüll, Müllmax)
AVV/EWC Codes	12	~840 Codes; SEPA Thesaurus mappt Begriffe → Codes
Construction Materials	14	LAGA M20 + ÖKOBAUDAT: Klassifikation & Ökobilanz (optional)

Merksatz: Domänen helfen beim Scope – für MVP priorisieren wir klein & stabil.

Available Data Volume (Potenzial vs. Vollimport)

Viele Quellen sind riesig. Für den Chatbot ist wichtiger: „Was wird wirklich gefragt?“
→ Darum: MVP-Graph klein halten und große Datenräume (Produkte/Chemie) nur bei Bedarf per API holen.

Quelle	Größe	Typ
PubChem	118,000,000	Chemische Verbindungen
Icecat	15,000,000	Consumer-Produkte
ECHA C&L	5,000,000	Chemie-Klassifikationen
Open Food Facts (DE)	400,000	Lebensmittel/Barcode/Verpackung
Stiftung EAR	50,000	Elektro-Geräte/Hersteller
SEPA Thesaurus	10,000	Synonyme für Abfallbegriffe
GESTIS	8,800	Sicherheitsdaten (Arbeitsschutz)
BSR Abfall-ABC	2,000	Abfall-Vokabular
… + lokale Quellen	—	z. B. AVV (840) & Frankfurt Facilities (~50)

Kannst auch selbst screen

Wenn wir alles importieren…

→ 100+ Mio. Knoten
(zu groß für MVP)

Besser: „destillieren“

MVP ≈ 25k
+ Barcode ≈ 150k
+ Full Chem ≈ 500k

Messgrößen/Mehrwert: (1) Abdeckung (wie viele typische Items können wir beantworten?), (2) Regel-Tiefe (Lookup vs. Rückfrage), (3) Ortsgenauigkeit (Campus > Stadt).

Priorities

Zielbild für die Demo: Der Bot beantwortet „Wie entsorge ich X?“ nachvollziehbar – inkl. Rückfrage, wenn nötig.

Foundation

- AVV-Hierarchie importieren
- Vokabular + Synonyme (Abfall-ABC + SEPA)
- Frankfurt Facilities hinzufügen

Conditional Logic

- Decision Trees für „Mirror Entries“
- Rückfragen als Graph-Knoten (Conditions/Questions)
- Regeln aus Satzungen/Container-Dokumenten ableiten

University Context

- Campus-Orte & Kontakte
- Optional: Labor-Chemie (GESTIS Subset)
- ElektroG-Sammelgruppen (EAR) für Routing

API Anbindung & Entwicklung Connectoren

- Große Datenräume „on demand“ (PubChem, OFF, …)
- Caching/Rate-Limits berücksichtigen

Was heißt „Ranked Rules“?

Wenn mehrere Regeln passen, wählen wir die beste:

1) Campus-Regel
2) Stadt/Frankfurt-Regel
3) Default/Allgemein

→ sorgt für konsistente Antworten, auch bei regionalen Unterschieden.

Demo-Scope (einfach):
10–20 Items • 2–3 Decision Trees

Organisatorisches

Fokus heute: Datenbasis, Integration, offene Entscheidungen

✅ Was steht

Schema ist klar (3 Layer + Provenance).

Quellen-Inventar liegt vor (Links + Notizen).

Integrationsstrategie ist definiert (Import / API / Regeln).

🔎 Offene Entscheidungen

Top-Quellen verifizieren (Format, Lizenz, Beispiel-Record)

MVP-Scope festlegen (Campus-only vs Campus-first + City-Fallback)
Demo-Set definieren (z. B. 10–20 Items + 2–3 Decision Trees)
Evaluation-Kriterien festlegen (Abdeckung, Antwortqualität, Usability)

Diskussionsfragen (Scope & Evaluation)

Welche Domänen sind Must-have im MVP (z. B. Elektro, Batterien, Packaging, Labor)?

Welche Evaluation ist gewünscht (Metriken & Setup)?
Gibt es eine Abschlusspräsentation?
Wie lange haben wir Zeit?

7) Roadmap

Fokus: „stabil integrierbar“ zuerst, Heavy-Domains bewusst später

Datenbeschaffung

- **Lebensmittel** (Open Food Facts)
- **Elektronik** (Stiftung EAR)
- **Chemikalien** (PubChem)

Datenbereinigung

- Deutsche Mülldaten
- AVV / EWC Codes
- non-essential Daten entfernen

Import

- Bereinigte Daten importieren
- Hierarchie anpassen

Evaluation

- Optional: Open Food Facts / iFixit / PubChem Connector (API + Cache).
- Abdeckung messen mit Testfragen + qualitative Demo-Hardening.
- Link-Inventory finalisieren (verifiziert) + klare Annahmen/Limitations.